

大语言模型为什么能像人一样说话和思考？

李航，张少华，林苑

1 引言

我们每天都在使用大语言模型（Large Language Model, LLM）。一个明显的感受是，它们似乎真的能够理解我们的语言，虽然有时也会出现幻觉。另一方面，观察 LLM 输出的思维链，也就是其推理过程的语言表示，我们会感到它们好像真的能像人一样思考。

本文讨论：**LLM 的语言和思考能力是怎样的能力？这些能力是如何通过其实现原理和方法、乃至工作机制形成的？**（见图 1）

LLM 技术是人类创造出来的，其实现原理是清楚的，但其工作机制（Mechanics）仍未被充分理解。LLM 规模极其庞大，工作机制极其复杂，给对其能力的研究带来了很大困难。

ChatGPT 问世以来，已有大量关于 LLM 机制和特性的研究，特别是近年关于工作机制（或可解释性）的研究。这些工作从不同角度对这一 AI 的核心课题给出了一定程度的回答。但仍有许多问题有待今后的研究。

本文将对 LLM 的基本原理和实现方法做一总结，也对 LLM 工作机制的研究进行简单的介绍，包括字节跳动做的 LLM 记忆机制的工作；在此基础上，对 LLM 的能力形成提出自己的看法。本文包含三个主要论点。

- **LLM 学习到的是语言使用和推理的模式，重要的是学到了其高阶模式。** LLM 的学习属于机器学习，其学习得到的内容本质上是数据中的统计规律，或者说数据中的模式（Patterns）。语言数据内容丰富，包含了词汇、语法、语义、语用信息和世界知识。我们可以看到，LLM 不仅学习到了与词汇和语法相关的低阶模式，而且也学习到了与语义、语用和世界知识相关的高阶模式（Higher Order Patterns）。之前的语言模型往往做不到这一点，而这正是 ChatGPT 以及后续的 LLM “涌现”出来的能力。因此，认为 LLM 仅仅学到了语言的形式而没有学到

内容的观点（例如后述乔姆斯基的看法）并不能令人信服。

- **可以用 Next Token Prediction (NTP) 来概括其基本实现原理，但整体能力是由策略、模型、算法及数据这几个要素共同决定的。** LLM 的学习和推理的过程是 NTP，但这只是表面的形式，其具体的实现方法以及其特点更为重要。预训练中使用的极大似然估计（等价于数据压缩）是估计词元序列数据的概率分布。后训练的强化学习旨在微调模型，使其成为最优词元序列生成的策略函数。作为模型的 Transformer 具有极强的语言和知识表示能力。随机梯度下降的优化算法则能帮助找到具有良好泛化性的解。LLM 的关键在于对这些技术的系统整合与规模化实现。有观点将 LLM 的成功简单归因于 NTP，这是过于简化的理解。
- **LLM 的内部机制已得到一定的解析和理解。** 近年 LLM 可解释性研究取得了一定进展，现在 LLM 对我们来说已不再完全是黑盒。LLM 中的特征可以通过 SAE 等工具提取出来，特征之间形成的回路也可以利用 CLT 等工具追踪。字节跳动最近的工作进一步揭示了 LLM 中特征在学习过程中被记忆、在推理中被检索的规律。随着未来研究的不断深入，LLM 的工作机制会越来越多地被我们解析和理解。



图 1: LLM 的语言和思维能力、工作机制、实现原理和方法之间的关系。

2 人类的语言理解和思考

首先整理人类的语言理解和思考的特点。

2.1 语言理解




图 2: 人的语言理解过程

语言处理分为理解和生成。人类的语言理解可从内部视角和外部视角定义。内部视角是指人在心智 (Mind) 中对语言的理解；外部视角则是观察到的人对语言的理解。

内部的语言理解涉及人的心智中对语言的表示。其中包括概念的 Grounding，即将听到或看到的语言与已有知识联系起来。例如，当人听到“大熊猫”时，会把自己关于大熊猫的知识联系起来。

外部的语言理解往往可以从完成任务的角度来看，有目标，也有结果。对话，例如问答，也可以看作是完成的过程。（图灵测试是从外部视角判断计算机是否能够理解语言的。）

具身认知假说认为，人的语言理解是通过意识中产生表象 (Image) 来实现的。例如，回答“大猩猩是否有鼻子？”这个问题时，脑海中会浮现大猩猩的表象。

语言在形式上是序列数据，无论是语音还是图像中的文字，通常需要按顺序处理；但在人的大脑中，其理解过程涉及层级化与并行处理。

语言同时包含词汇、语法、语义和语用信息，而语义和语用又与世界知识密切相关（见图 2）。从抽象程度看，前两者属于低层信息，而后两者属于高层信息。上面的例子中，“大猩猩”、“有”、“鼻子”属于语义信息，而整个疑问句所表达的意图属于语用信息。

无论何种语言，语法差异多大，通常都可以看作由不同颗粒度的 Chunk



图 3: Chunk 分析示例：框内的短语是 Chunk

组成，并可从 Chunk 的角度进行分析（见图 3）。

2.2 思考

人在思考过程中，大脑神经系统中的神经元被激活，在脑中形成神经表征。同时，在人的心智中，尤其是意识层面，会形成符号表示或表象。产生符号表示是传统认知科学的重要观点，而产生表象则是具身认知学所主张的。

具身认知学认为，人的推理在很大程度上依赖类推。例如，认为“这款手机和我以前用的那款是同一个品牌，所以质量应该也不错”。

严格的数学推导中，主要使用逻辑推理规则（如三段论）或计算规则（如加减乘除规则）。但这些都是特定场景下才有的。

可以用贝叶斯推断对人的推理过程加以刻画。例如，福尔摩斯侦探过程中的推理可以看作是贝叶斯推断。

3 LLM 的学习和推理

LLM 是一种语言模型，其处理形式可以用 Next Token Prediction (NTP) 来概括，但其整体机制更加复杂，不能简单用这一概念来理解。

在预训练阶段，对词元（Token）序列的数据进行极大似然估计，得到生成词元序列的最优模型。在后训练阶段，用强化学习进一步微调模型，使其成为生成合理的词元序列的意义上的最优策略；实现上学习词元级别的策略，但可以近似看作是学习序列级别的策略。

在模型架构上，LLM 采用自回归的 Transformer 解码器；在优化算法上，使用随机梯度下降（如 AdamW）。

LLM 的语言能力是模型结构、优化算法、训练策略以及语言数据特性共同作用的结果。预训练决定了基本的语言和推理能力，后训练则进一步提升推理能力和完成任务能力。

本节总结 LLM 的基本原理与实现方法。内容涉及技术细节，读者可根据情况跳过。

3.1 预训练

在预训练（Pre-Training）中，LLM 表示的是词元序列的生成概率。根据概率乘法定理，词元序列 $\mathbf{w}$ 的概率可以写作

$$P_{\boldsymbol{\theta}}(\mathbf{w}) = \prod_{t=1}^T P_{\boldsymbol{\theta}}(w_t | w_{<t}), \quad \mathbf{w} = w_1 w_2, \dots, w_T \quad (1)$$

学习的目标是估计模型参数 $\boldsymbol{\theta}$ ，用以计算条件概率 $P_{\boldsymbol{\theta}}(w_t | w_{<t})$ 。预测的目标是根据条件概率 $P_{\boldsymbol{\theta}}(w_t | w_{<t})$ 自回归地生成词元序列。LLM 通常以 Transformer 解码器为模型，表示条件概率 $P_{\boldsymbol{\theta}}(w_t | w_{<t})$ 。

学习通过极大似然估计进行，即最大化训练数据的似然函数，或等价地最小化交叉熵损失。估计模型的参数，等价于对训练数据进行无损压缩时的建模。交叉熵损失写作

$$L(\boldsymbol{\theta}) = \mathbb{E}_{\mathbf{w} \sim P_{\text{data}}} \left[\sum_{t=1}^T -\log P_{\boldsymbol{\theta}}(w_t | w_{<t}) \right] \quad (2)$$

其梯度函数是

$$\nabla_{\boldsymbol{\theta}} L(\boldsymbol{\theta}) = \mathbb{E}_{\mathbf{w} \sim P_{\text{data}}} \left[\sum_{t=1}^T -\nabla_{\boldsymbol{\theta}} \log P_{\boldsymbol{\theta}}(w_t | w_{<t}) \right] \quad (3)$$

无损压缩第一步估计数据分布的模型，第二步根据模型对数据进行编码。这里只有第一步的建模，并没有第二步的编码。Ilya Sutskever 提出的“压缩即智能”观点，可作为对 LLM 预训练建模的一种诠释。

极大似然估计在渐近条件下，也就是数据量趋于无穷时，拥有优良的性质。考虑概率分布空间，学习的目标是在参数化分布族 $\{p_{\boldsymbol{\theta}}(\mathbf{x})\}$ 中找到最优分布。参数化分布族在空间中构成流形（Manifold）。假设真实数据分布 $p_{\text{data}}(\mathbf{x})$ 位于流形之外，如图 4 所示。在一定正则条件下，极大似然估计参




图 4: 极大似然估计得到的分布依概率收敛于真实分布在参数化分布族上的 KL 投影。

数 $\hat{\theta}_{\text{MLE}}$ 所表示的分布依概率收敛于真实分布在流形上的 KL 投影，也就是在 KL 散度意义下与真实分布间差异最小的分布。

$$\hat{\theta}_{\text{MLE}} = \arg \min_{\theta \in \Theta} \text{KL}(p_{\text{data}}(\mathbf{x}) \parallel p_{\theta}(\mathbf{x})) \quad (4)$$

如果真实分布存在于参数化分布族之内，那么极大似然估计参数 $\hat{\theta}_{\text{MLE}}$ 所表示的分布依概率收敛到真实分布。

3.2 后训练

LLM 的后训练包括 SFT (Supervised Fine-Tuning) 和 RL (Reinforcement Learning) 两个阶段。后者的一个特殊情况是 RLHF (Reinforcement Learning from Human Feedback)。

在后训练的 RL 中，LLM 是策略函数，其中状态是目前为止的词元序列，动作是下一个词元。奖励一般是定义在词元序列的最后位置，表示序列的合理性，其他位置的奖励为零。

后训练 RL 通常采用策略梯度方法，使用策略函数进行动作轨迹也就是词元序列的展开 (Rollout)。而 SFT 可以看作是模仿学习，其目标是拟合给定的示例数据。

学习的目标是最大化回报，也就是奖励的期望，以微调 LLM 的模型参数 θ 。策略函数 $\pi_{\theta}(y_t | \mathbf{x}, y_{<t})$ 表示在给定提示 $\mathbf{x}$ 和已生成前缀 $y_{<t}$ 的条件下，下一个词元 y_t 的生成概率。最简单的 REINFORCE 算法中，回报的梯

度函数写作

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\mathbf{x} \sim P_{\text{data}}, \mathbf{y} \sim \pi_{\theta}} \left[R(\mathbf{x}, \mathbf{y}) \sum_{t=1}^T \nabla_{\theta} \log \pi_{\theta}(y_t \mid \mathbf{x}, y_{<t}) \right] \quad (5)$$

其中 $\mathbf{x}$ 表示提示的词元序列, $\mathbf{y}$ 表示回复的词元序列, $R(\mathbf{x}, \mathbf{y})$ 表示其奖励。实际方法中 (如 PPO、GRPO), 引入优势函数与正则项以稳定训练, 但都属于策略梯度方法。

从生成过程的形式上看 (式 (3) 和 (5)), 后训练阶段仍然是逐个生成词元, 这与预训练存在相似性。不同之处在于, 后训练的目标不再是学习数据分布, 而是学习生成奖励的期望 (平均) 最大的序列。

事实上, 后训练的 RL 可以从两个层面定义: **词元级别和序列级别**。目前 RL 的实现都是词元级别的, 如上面所述。但从概念理解的角度, 序列级别的 RL 更为直观。词元级别的 RL 通常是对序列级别 RL 的一种近似 [9]。

序列级别的 RL 的目标是在给定提示 $\mathbf{x}$ 的条件下, 学习如何生成奖励期望最大的回复 $\mathbf{y}$ 。其梯度可以表示为:

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\mathbf{x} \sim P_{\text{data}}, \mathbf{y} \sim \pi_{\theta}} \left[R(\mathbf{x}, \mathbf{y}) \nabla_{\theta} \log \pi_{\theta}(\mathbf{y} \mid \mathbf{x}) \right] \quad (6)$$

其中, 奖励函数 $R(\mathbf{x}, \mathbf{y})$ 评估回复的合理性, 策略 π_{θ} 通过自回归方式逐词元生成完整序列。在这种情况下, 词元级别和序列级别的 RL 是等价的。

3.3 推理

可以认为, LLM 的推理 (Reasoning) 是在由词元序列构成的巨大空间中的搜索。我们将这些词元序列称为“陈述” (Statement)。陈述表达一定内容, 是推理的基本单元。它既可以是自然语言 (如一段文字), 也可以是形式语言 (如一段代码); 既可以表达严谨的逻辑推理, 也可以表达类比推理; 思维链可能包含多个陈述。

LLM 在搜索过程中, 不断选择合适的推理路径, 最终得到答案 (见图 5)。在经过 RL 训练之后, 模型参数在推理阶段保持固定, 但可以通过生成更长的思维链、采样更多路径等方式, 在陈述空间中进行更充分的搜索, 从而找到更优的答案, 这一过程能实现 Test-Time Scaling。

RL 训练能够提升模型的推理能力。它通过优化策略, 使模型更倾向于生成高质量的中间结果与最终结果, 本质上是在增强搜索能力 [6]。




图 5: LLM 推理是在陈述空间中的搜索示意

将推理形式化为陈述空间中的搜索，使 LLM 能够超越单纯的语言理解和生成，迈向具备“思考”能力的更高层次智能。

3.4 优化算法：随机梯度下降

学习的策略确定以后，接着就是要使用优化算法，估计最优参数，以优化目标函数。神经网络只要其学习的损失函数关于参数可导，就可以通过随机梯度下降（SGD）及其变体进行优化。LLM 亦是如此。

实验证明，使用 SGD 及其变体（如 AdamW）不仅能使损失函数收敛到较好的极小值区域，而且学到的模型通常具有较好的泛化能力。（见图 6）

SGD 往往倾向于收敛到较为平坦的极小值区域，而这对深度学习的泛化性能起着重要作用。而且 SGD 的批量处理的规模较小时通常能有更好的泛化效果 [5]。

实验证明，深度学习模型往往是过参数化的，也就是说，模型容量远超数据规模。这与传统机器学习有所不同。训练损失函数呈双下降现象 [1]（图 7 是示意图）。在欠参数化区域，随着模型参数增加，训练损失下降而测试损失上升，传统机器学习处于这个区域。当训练损失接近为零后（过了插值阈值，即模型完全拟合训练数据的临界点），进入到过参数化区域，随着模型容量继续增加，训练损失持续接近为零，而测试损失也会随之下降，深度学习是在这个区域 [7]。




图 6: 随机梯度下降




图 7: 训练和预测损失曲线

经验表明, LLM 的预训练也处于过参数化区域, 因此通过 SGD 可以达到很好的泛化效果, 测试损失遵循 Scaling Law[4]。Scaling Law 是指损失函数随计算量、参数量和数据量呈幂律下降的规律。后训练 (RL) 也观察到类似趋势, 但其机制有所不同, 仍需进一步研究。

3.5 模型：Transformer

LLM 通常使用 Transformer 解码器架构。在语言和知识的表示方面起着重要的作用。尤其是 Transformer 中的自注意力、前馈网络 (FFN)、残差连接。




图 8: Transformer 解码器架构

图 8 显示 Transformer 解码器的架构图。表 1 列出了代表性 LLM 的模型规模。

模型	训练数据	参数量	层数	上下文长度	词表大小	模型维度
GPT-1	1B Tokens	117M	12	512	40k	768
GPT-2	10B Tokens	1.5B	48	1024	~50k	1600
GPT-3	300B Tokens	175B	96	2048	~50k	12288

表 1: GPT 模型规模、训练数据、上下文窗口与词表大小

自注意力

Transformer 中的每一层都有一个自注意力（Self Attention）模块。自注意力的主要作用是对输入表示向量与上下文的表示向量进行线性组合，产生新的输出表示向量。

首先对当前位置的输入表示向量与其上下文的输入向量进行线性变换，得到查询矩阵、键矩阵和值矩阵。注意力的计算如下

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d}}\right)V \quad (7)$$

其中， Q (Query)、 K (Key)、 V (Value) 分别是由输入词元线性变换得到的查询矩阵、键矩阵和值矩阵， d 是键向量的维度， $\sqrt{d}$ 为缩放因子。最后将得到的结果进行线性变换得到当前位置的输出向量。为了保证当前位置的向量只与之前位置的向量做线性组合，矩阵计算中需要进行掩码。




图 9: 自注意力计算示意

从直观上理解，自注意力可以看作是一种键-值存储查询 (Key-Value Store Query)：对于每一个查询向量，计算它与所有键向量的相似度，以相似度为权重求所有值向量的加权和，作为结果。查询与键越匹配，对应的值在最终结果中所占比重就越大。它是一种“软的”键-值存储查询，极端情况，如果向量都是独热向量，自注意力计算等价于基于符号的键-值存储查询。图 9给出了自注意力计算的示例。

以上叙述的是单头的自注意力，实际使用多头自注意力，在不同子空间并行计算注意力，然后拼接并线性变换。不同的注意力头可以关注不同类型的组合关系，例如，有的头可能关注语法，有的头关注语义，有的头关注语用。通过多头机制，模型能够从多个角度捕捉表示向量之间的组合关系。

自注意力是对表示向量的组合 (Composition)。相关的知识也存储在线性变换的矩阵之中。语言最本质的特点之一就是具有组合性 (Compositionality): 也就是单词组合成短语, 短语组合成句子, 句子组合成篇章。自注意力机制正好支持这种组合性。每一层的注意力计算都在对输入序列进行重新组合, 而多层累加计算实现了从局部到全局、从浅层到深层的逐级组合。

前馈神经网络 (FFN)

Transformer 中的每一层都有一个两层前馈神经网络 (FFN) 模块。

$$\mathbf{y} = \mathbf{W}_2 \text{ReLU}(\mathbf{W}_1 \mathbf{x} + \mathbf{b}_1) + \mathbf{b}_2 \quad (8)$$

其中, $\mathbf{x}$ 是输入向量, $\mathbf{W}_1$ 和 $\mathbf{W}_2$ 是权重矩阵, $\mathbf{b}_1$ 和 $\mathbf{b}_2$ 是偏置, ReLU 是激活函数, $\mathbf{y}$ 是输出向量。图 10 给出两层 FFN 的简单示例。

FFN 的主要作用是对输入向量进行特征检测, 并将检测到的特征表示为输出向量。相关的知识也存储在神经网络的权重矩阵之中。




图 10: 两层前馈神经网络结构示意图

FFN 中间层的每个神经元可以看作是在检测输入向量中的特征。具体来说, 输入向量 x 与权重向量 (W_1 中的行向量) 进行点积运算。如果输入方向与权重方向相同, 点积结果为正, 经过 ReLU 后表示的特征被激活; 如果方向相反, 点积结果为负, 经 ReLU 后表示的特征不被激活; 由此得到中间向量。输出层的神经元是线性神经元, 通过线性变换 (使用 W_2), 将中间向量转换为输出向量。输入和输出向量的维度相同, 而中间向量的维度 (也

就是中间层的神经元数)一般是其 4 倍左右,这样可以进行更多的特征检测。

FFN 承担了特征检测器的角色,训练过程就是使权重矩阵学会有效的特征检测模式。对应的知识存储在权重矩阵之中。近年来,可解释性研究表明,神经元对特征的表示并非“一对一”,而呈现出叠加(Superposition)现象。这一点将在 4.2 节详细介绍。

Transformer 的各层 FFN 存储的知识有所不同。研究发现:浅层更多关注表示词汇和语法信息;中层捕捉更多的语义信息;深层则掌握可能与上下文、语用、推理相关信息。

现代 LLM 规模庞大(见表 1),参数量的扩展使其能够容纳大量的知识。特别是在 FFN 层引入混合专家(MoE)结构后,可以大幅提升模型的容量,使其能够表示和存储更丰富的知识。

残差连接

Transformer 在每一层的自注意力模块和 FFN 模块后均接有残差连接。

$$\mathbf{x}_{l+1} = \mathbf{x}_l + f(\mathbf{x}_l) \quad (9)$$

f 表示自注意力或 FFN。基于 LLM 残差结构,不同层学习到的表示可以通过加法路径在更深层中被累加和重用。


LLM 可以被理解为由自注意力与 FFN 形成的不同深度子网络的隐式集成(Implicit Ensemble)。如图 11 所示,假设有三个函数串联,若它们之间增加了残差连接,那么整个网络可以被解释为由不同深度的子网络构成的隐式集成。

残差连接有以下几个作用:促进信息与梯度的跨层传播,使浅层表示能够直接影响深层,提高深层网络的可训练性。


残差连接给 LLM 的可解释性分析带来更多的困难。LLM 的自注意力权重可以用于分析不同位置词元之间的相关关系,但由于信息可以通过残差连接在层间传播,这些相关关系未必仅来源于当前层。

其他机制

LLM 通过位置编码(如 RoPE)显式地表示词元的序列位置,这与 RNN(Recurrent Neural Network)通过模型结构隐式地表示位置信息显著不同。



(a) 残差网络



(b) 等价的隐式集成网络

图 11: 残差神经网络的例子

层归一化（通常采用 Pre-Norm 形式）是促使 Transformer 稳定训练的重要机制之一。

此外，在保持 Transformer 基本架构不变的前提下，当前 LLM 引入了多项关键改进技术。例如：混合专家 (MoE) 提高模型容量与计算效率；Swish 激活函数替代 ReLU 激活函数；SwiGLU 结构改进 FFN 模块；Multi-Query Attention (MQA) 或 Grouped-Query Attention (GQA) 提高注意力计算效率。这些改进主要发生在模块设计与计算实现层面，整体架构并没有根本变化。

4 LLM 的工作机制

LLM 的研究可以从三个视角进行：机器学习方法与理论、外部提示实验分析、内部工作机制研究。若将 LLM 比作人脑，工作机制的研究则对应着脑科学实验。

4.1 特征叠加

神经网络的每一层上都可能存在着“特征叠加” (Superposition) 现象。传统的观点认为，一个神经元表示一个特征。然而，大量实验表明，这种理

想化的情况在实际网络中比较少见。相反，神经元与特征之间往往呈现的是多对多的对应关系：即一个神经元参与表示多个特征，一个特征由多个神经元共同表示。

Anthropic 研究团队提出了特征叠加假说 (Superposition Hypothesis) [2]。其核心思想是：**通过特征叠加，神经网络的一层神经元可以近似表示远大于其数量的特征**，代价是特征之间存在一定程度的干扰。

神经网络的一层（称为实际层）可以表示为：

$$\mathbf{h} = \text{ReLU}(\mathbf{W}\mathbf{x} + \mathbf{b}) \quad (10)$$

其中， $\mathbf{x}$ 是输入向量，位于输入空间中； $\mathbf{W}$ 是权重矩阵； $\mathbf{b}$ 是偏置向量； $\mathbf{h}$ 是输出向量或特征向量；ReLU 是激活函数。

特征叠加理论指出，存在一个更宽的假想神经网络层，使用更多神经元来显式表示大量的特征：

$$\bar{\mathbf{h}} = \text{ReLU}(\bar{\mathbf{W}}\mathbf{x} + \bar{\mathbf{b}}) \quad (11)$$

其中， $\bar{\mathbf{h}}$ 是特征向量，其每一维对应一个特征，且满足 $\dim(\bar{\mathbf{h}}) \gg \dim(\mathbf{h})$ ，即宽层的维度远大于实际层的维度； $\bar{\mathbf{W}}$ 和 $\bar{\mathbf{b}}$ 是权重矩阵和偏置向量。

重要的是宽层的特征向量 $\bar{\mathbf{h}}$ 是稀疏的，而实际层的特征向量 $\mathbf{h}$ 是稠密的。稀疏性意味着对于每个输入，只有少数特征被激活（例如，一万个特征中只有几十个被激活），使得不同特征之间的干扰较小。




图 12: 原始的前馈神经网络与近似等价的更宽的神经网络

特征叠加假说认为，宽层与实际层之间存在近似等价关系。具体而言，两者都能通过线性变换近似复原输入向量 $\mathbf{x}$ ，得到近似重建 $\hat{\mathbf{x}}$ ，如图 12 所

示。因此，可以认为，实际的网络中，稀疏的特征向量 $\bar{h}$ 被压缩到了稠密的特征向量 h 之中。稀疏的特征向量 $\bar{h}$ 是近乎相互独立的（非叠加的），稠密的特征向量 h 是被叠加的。

高维几何理论为宽层的存在性提供了一定的保证。在相关定义的条件下， n 维空间中近乎正交的基向量个数可以达到 n 的指数级。假设 $\bar{v}_1, \bar{v}_2, \dots, \bar{v}_m$ 是输入空间的一组近乎正交的基向量，则输入向量可近似分解为：

$$\mathbf{x} \approx \sum_{i=1}^m \bar{h}_i \bar{v}_i, \quad \bar{h} = (\bar{h}_1, \bar{h}_2, \dots, \bar{h}_m) \quad (12)$$

这里每一个基向量 $\bar{v}_i$ 和其激活值 $\bar{h}_i$ 对应一个特征。基向量近乎正交，特征向量稀疏，就能很好地表示输入向量，并且减少特征之间的干扰。

特征叠加假说认为，深度学习的方法能够达到这样的效果，也就是实际层（稠密特征向量）实现了对宽层（稀疏特征向量）的压缩，或者说实际层（稠密特征向量）隐式地蕴含了宽层（稀疏特征向量）。这主要有两方面的原因。

首先，一般的输入向量 $\mathbf{x}$ 所包含的特征数量是稀疏的。例如，在处理“我访问了金门大桥”中的“桥”这一词元时，宽层特征向量 $\bar{h}$ 中，可能只有少数几个特征被激活（如“金门大桥”、“旧金山”、“桥梁结构”、“旅游景点”等），其他特征取值均为零。这种稀疏性保证了大量近乎正交特征之间的干扰足够小，使得叠加机制切实可行。

其次，在训练过程中，神经网络通过梯度下降最小化损失函数。当网络面临“表示尽可能多的特征”与“使用尽可能少的神经元”这两个目标时，特征叠加成为一种自然的优化结果。另外，ReLU 激活函数的使用也促进了特征向量的稀疏化，因为较弱的激活值会被截断为零。

上述特征叠加假说的合理性，已在 Anthropic 的玩具模型（toy model）模拟实验中得到验证，并在后续稀疏自编码器（Sparse Autoencoder）的开发与应用中获得了进一步的支持。

4.2 SAE：特征分析

稀疏自编码器（Sparse Autoencoder, SAE）可以用于分析神经网络，发现其中具有可解释性的特征。在 LLM 的可解释性研究中，通常将其应用于 Transformer 的残差流，即在每层的输出表示向量上。

SAE 与特征叠加理论形成了互补关系。特征叠加可以被视为一种压缩过程：模型隐式地通过高维且稀疏的特征向量对输入向量进行表示。而 SAE

则可以被视为一种“解压”方法：将输入向量分解为高维且稀疏的特征向量。这种“压缩—解压”的关系，使 SAE 成为研究和分析特征叠加现象的重要工具。

SAE 由编码器 (Encoder) 和解码器 (Decoder) 组成。首先，编码器通过非线性变换将输入向量转换为高维且稀疏的特征向量：

$$\mathbf{h} = \text{ReLU}(\mathbf{W}_e \mathbf{x} + \mathbf{b}_e) \quad (13)$$

其中， $\mathbf{x} \in \mathbb{R}^n$ 是来自 LLM 某一层的残差流， $\mathbf{W}_e$ 是编码器权重矩阵， $\mathbf{b}_e$ 是偏置向量， $\mathbf{h} \in \mathbb{R}^m$ 是特征向量，满足 $m \gg n$ ，即特征维度远大于输入维度。

解码器通过线性变换从特征向量重构原始输入向量：

$$\hat{\mathbf{x}} = \mathbf{W}_d \mathbf{h} + \mathbf{b}_d \quad (14)$$

其中， $\mathbf{W}_d$ 是解码器权重矩阵， $\mathbf{b}_d$ 是偏置向量。解码器采用线性变换（无激活函数），这一设计与特征叠加理论中的特征的线性组合假设一致。

SAE 的训练中在两个目标之间进行权衡：一方面，使重构向量 $\hat{\mathbf{x}}$ 尽可能接近原始输入向量 $\mathbf{x}$ ；另一方面，引入 L_1 或近似 L_0 正则化来促进特征向量 $\mathbf{h}$ 的稀疏性。

在实际操作中，SAE 的训练需要从目标 LLM 中提取大量数据。将大规模语料输入到 LLM，收集模型在处理每个词元时产生的激活向量（如每一层的残差流）。这些向量 $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$ 构成 SAE 的训练数据集。训练完成后，对于任意输入 $\mathbf{x}$ ，编码器输出的 $\mathbf{h}$ 通常呈现出较强的稀疏性。

通过 SAE 得到的稀疏激活特征与特征叠加理论的预测一致，即模型可能将远多于神经元数量的潜在概念编码在神经元中。例如，研究者在对大语言模型进行分析时，已经成功提取出数十万到百万量级的特征，其中一些特征具有明显的语义含义，例如与实体（如“金门大桥”）或行为（如“谄媚”，Sycophancy）相关的特征。

分析表明，大语言模型中的特征往往呈现出一定的层次化结构：浅层基本是表示输入的词法与简单语法的特征；中间层有大量复杂语法和基本语义的特征；深层主要是复杂语义、推理实现和输出表达的特征。

4.3 记忆机制

字节跳动的工作提出了功能词元假说，揭示了 LLM 的记忆机制的基本特点 [8]。功能词元假说 (Function Token Hypothesis) 认为，LLM 中特征

的记忆是围绕着功能词元展开的，特征在一个上下文的检索，也是通过功能词元进行的。

功能词元是指在训练语料中出现频率最高的词元，大部分对应于语言学中的功能词，在语法和上下文连接上起着关键作用。例如，冠词“the”、标点符号（逗号、句号）、换行符等。与之相对的是内容词元，表达明确且丰富的语义信息。统计表明，在大规模预训练语料中，前 100 多个高频词元就占了所有词元出现次数的大约 40%。

在 LLM 的预训练阶段，学习过程呈现出以功能词元为中心的显著特点。通过将训练损失按照功能词元和内容词元的四种组合进行分解观察，结果发现，“功能词元 → 内容词元”的损失函数下降得最慢。也就是说，根据功能词元来预测下一个内容词元是最困难的。从语言学的角度看，这是合理的，因为功能词元往往标志着前一个语言单元（Chunk）的结束，要预测它之后的内容词元，需要对从开头到当前位置的整个上下文有准确的理解。可以推断，正是这种最难的预测任务，成为了驱动模型优化的主导力量。

另一个发现是功能词元在训练的过程中能激活大部分特征（在不同的上下文激活不同的稀疏特征）。将功能词元和特征之间建立二部图。如果一个功能词元在某个上下文激活了某个特征，就在两者之间建立一个边。随着训练的深入，二部图上的边不断增加。最后，少量功能词元能与大部分特征之间建立联系，前 10 个高频词元激活 70% 的特征，也就是说，这些功能词元能（在不同的上下文）激活大部分特征。这里也存在着幂律分布。

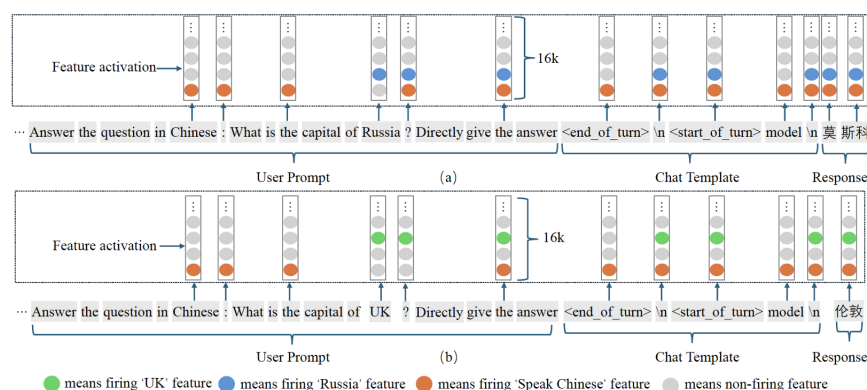


图 13: LLM 推理过程中功能词元发挥着记忆检索的核心作用。

在推理过程中，功能词元发挥着记忆检索的核心作用。它们能从上下文

中动态地激活最具预测性的特征，从而指导下一个词元的生成。例如，如图 13 所示，当提示为 “Answer the question in Chinese: What is the capital of Russia?” 时，功能词元（如冒号 “:” 和换行符）会激活上下文中 “用中文回答” 和 “俄罗斯” 等特征，同时抑制无关特征，最终引导模型用中文生成答案 “莫斯科”。这种动态的特征选择与组合能力，正是功能词元区别于内容词元的关键特性。

功能词元之所以在 LLM 中发挥如此关键的作用，是训练目标、学习算法、模型架构和语言特性共同作用的结果。首先，下一词元预测的训练目标（交叉熵损失）要求模型最大化预测准确性，而梯度下降算法总是优先降低损失最大的部分。其次，Transformer 架构中的前馈网络层能将知识（特征）进行很好的表示和记忆，自注意力层能将低阶的知识（特征）有效地组合成高阶的知识（特征）。最后，自然语言本身的结构特性起到了决定性作用，文本总是被功能词元分割成嵌套的 Chunk（可以是短语、句子或段落）。因此，对功能词元之后的预测，需要理解从文本开头到该位置的整个上下文语义。这是一项极具挑战性的任务，促使功能词元在训练中获得连接大部分特征的能力，并在推理时重新激活最具预测性的特征。

功能词元假说对 LLM 训练实践具有深刻启示。其中最重要的一点是训练数据的格式至关重要。多项研究的结果印证了这一点。在后训练阶段，仅需少量训练步骤就能显著提升模型的指令遵循、思维链推理等能力。这可能是因为后训练通过调整功能词元的激活模式，激活了预训练期间已经习得的特征。例如，功能词元（如 “thus”）在强化学习训练中能够显著提升推理性能。

4.4 CLT: 回路分析

回路（Circuit）是指在 LLM 中跨层连接特征的计算图，用于表示模型中的特征是如何被激活和传播的。因为 SAE 只能看到单层的特征，具有较大的局限性。为了分析跨层的特征的连接和影响关系，研究者提出了 CLT（Cross Layer Transcoder，跨层转码器）方法。

CLT 的工作原理是：以某一层的残差流 $\mathbf{x}^{(l)}$ 作为输入，模型将其映射到后续各层的残差流 $\mathbf{x}^{(l+1)}, \mathbf{x}^{(l+2)}, \dots, \mathbf{x}^{(L)}$ 。通过这种方式，CLT 能够学习到一个跨层对齐的特征字典，捕捉不同层之间的特征影响关系。

CLT 在每一层都有一个类似 SAE 的特征抽取模块，但其优化目标有很大不同。每一层的输出是复现的后续各个层的残差流。它由非线性变换（对

应编码器)、线性变换 (对应跨层映射) 以及线性解码变换组成:

$$\mathbf{h}^{(l)} = \text{ReLU}(\mathbf{W}_e^{(l)} \mathbf{x}^{(l)} + \mathbf{b}_e^{(l)}) \quad (15)$$

$$\mathbf{h}^{(l+k)} = \mathbf{T}^{(l \rightarrow l+k)} \mathbf{h}^{(l)} + \mathbf{b}_T^{(l+k)} \quad (16)$$

$$\hat{\mathbf{x}}^{(l+k)} = \mathbf{W}_d^{(l+k)} \mathbf{h}^{(l+k)} + \mathbf{b}_d^{(l+k)} \quad (17)$$

其中, $\mathbf{W}_e^{(l)}$ 是第 l 层编码器权重矩阵, $\mathbf{b}_e^{(l)}$ 是偏置向量; $\mathbf{W}_d^{(l+k)}$ 是第 $l+k$ 层解码器权重矩阵, $\mathbf{b}_d^{(l+k)}$ 是偏置向量; $\mathbf{T}^{(l \rightarrow l+k)}$ 是将特征从第 l 层映射到第 $l+k$ 层的跨层线性变换权重矩阵, $\mathbf{b}_T^{(l+k)}$ 是偏置向量。通过跨层线性变换, $\mathbf{T}^{(l \rightarrow l+k)}$ 实现从第 l 层特征空间到第 $l+k$ 层特征空间的线性投影。CLT 的训练目标由所有层的重构误差的最小化和稀疏性正则化组成。

基于 CLT 的分析结果可以构建归因图 (Attribution Graph), 直观地展示特征在模型各层之间的线性映射关系, 帮助理解 LLM 内部的知识表示和计算机制。




图 14: 基于 CLT 构建的归因图, 用于分析 LLM 的内部计算机制。

归因图的构建基于训练好的 CLT 模型。给定一个具体的输入提示, 首先运行原始 Transformer 模型, 记录各层的残差流 $\mathbf{x}^{(l)}$ 。然后, 利用 CLT 提取每一层的稀疏特征 $\mathbf{h}^{(l)} = \text{ReLU}(\mathbf{W}_e^{(l)} \mathbf{x}^{(l)} + \mathbf{b}_e^{(l)})$, 并通过跨层映射矩阵 $\mathbf{T}^{(l \rightarrow l+k)}$ 分析特征之间的映射关系。

归因图是一个有向无环图, 表示从输入词元到输出词元的计算路径。在这个图中, 节点代表模型中激活的特征或词元嵌入, 而边则代表节点之间的影响关系。具体而言, 如果特征 i 在层 l 的激活 ($h_i^{(l)} > 0$), 且通过跨层映射 $\mathbf{T}^{(l \rightarrow l+k)}$ 对特征 j 在层 $l+k$ 的激活有显著贡献, 则在图中添加从节点 (i, l) 到 $(j, l+k)$ 的有向边。

为了提高归因图的可解释性，采用剪枝技术对图进行精简。通过设置阈值，只保留激活强度和贡献度显著的节点和边。进一步使用梯度回传，识别对最终输出贡献最大的路径。得到的精简归因图能够更清晰地展示模型中的特征激活和推理路径，揭示模型在特定场景中的核心特征回路。

5 LLM 的语言理解和推理

5.1 LLM 的能力

5.1.1 高阶模式

从其行为表现来看，大语言模型已展现出人类同等以上的语言与推理能力。以图灵测试为衡量标准，即考察其在对话中是否无法与人类区分，LLM 已达到了人类水平。

LLM 所习得的不仅限于语言的低阶模式，更涵盖了语言与推理的高阶模式。这一点在我们日常使用 LLM 时可以得到直观验证。例如，LLM 能够理解并执行“喜马拉雅山有多高，用英文回答”这类指令，体现了其语用能力；它还能够辨析“金门大桥与金拱门的关系”这类涉及概念异同的问题，显示出语义理解与世界知识的整合能力。

从内部机制的分析角度看，“金门大桥”、“谄媚”等概念特征在模型中的存在，同样揭示了 LLM 具备语义与语用层面的理解能力。

乔姆斯基曾批评 LLM 仅学习到语言的表层统计规律。然而，以上事实表明，这一判断并不成立。不过，这并不意味着 LLM 与人类语言能力完全等同。事实上，LLM 的语言机制与人类大脑存在显著差异。例如，人脑的语言理解依赖于布洛卡区与韦尼克区两个脑区的协同工作：前者主要负责语法处理，后者则承担词汇处理功能。

5.1.2 整体机制

大语言模型（LLM）的整体工作机制可以从训练方式、策略、算法和模型来理解（见图 15）。其训练方式通常包括预训练和后训练两个阶段，并通过两步训练融合，使模型在同一体系中同时具备语言理解、生成与推理能力。在机制上，LLM 基于自回归预测，即根据已有上下文逐步预测下一个词，这一过程也可以看作一种序列决策过程。




图 15: LLM 的机制可以从训练方式、策略、算法和模型来理解。

在预训练阶段，模型通过大规模语料学习统计规律，给定足够长的上文，下一个词元的概率分布往往会更加集中；而在后训练阶段，通过人类反馈或策略优化，使模型在相同上下文下更倾向生成最合理、最符合人类偏好的下文。

从技术实现上看，学习策略负责定义预测目标和优化方向，算法用于调整模型参数以达到最优目标，而模型结构则决定了表达能力，通过自注意力机制实现特征组合，通过前馈网络进行特征检测（非线性变换），并通过多层结构形成层次化表示。这些都对 LLM 的类人语言和推理能力起着重要作用。

模型性能的提升还体现出明显的规模效应：随着数据量、参数规模和计算资源的增加，模型能力会产生质的飞跃。同时，数据质量和训练设计（例如高质量语料和系统提示设计）也对效果至关重要。

这样训练得到的 LLM 中形成了大量的特征，表示着各种不同的概念，根据不同的上下文，这些不同的特征被激活，动态形成回路，实现复杂的语言处理和推理机制。

5.2 与人类能力的比较

表 2 对比了 LLM 与人类的能力。可以看出，LLM 在语言与推理任务上已具备与人类相当甚至超越人类的水平。然而，在其他能力维度上，两者不仅机制可能存在根本差异，其性能也并非简单可比。下面对此进行简要说明与讨论。

幻觉本质源于对事实的判断错误。LLM 自身无法解决幻觉问题。因为

表 2: LLM 与人类能力比较

能力维度	LLM
语言能力	达到或超过人类水平
推理能力	达到或超过人类水平
事实认知能力	有幻觉
多模态处理能力	本身不具备，但可以扩展为多模态模型
数学能力（计算、逻辑推理）	具有一定能力但有局限性
思考能力	不具备像人一样的结合语言、推理、多模态处理的机制
情感	语言和推理中有情感要素，但机制与人类不同
创造力	有一定程度的创造力
意识	不同机制

它学习的是语言数据中的统计规律。理论证明，在一定假设条件下，语言生成过程中一定会以一定概率产生幻觉 [3]。幻觉问题可通过其他机制加以缓解，比如，检索增强生成（RAG）。

人的思考包含多个方面，不仅涉及语言、推理和数学，还与五种感官（视觉、听觉、触觉、嗅觉、味觉）以及运动系统密切相关。具身认知假说认为，思考的过程并非纯粹的符号运算，而是基于身体的感知运动经验，在心智中进行模拟。当前的多模态大语言模型（MLLM）能够将语言推理与视觉、听觉等信息进行关联处理，但其推理过程通常发生在语言表示空间。这种处理方式与人类基于具身体验的、丰富的、有意识的思考有着本质区别。最近也有一些工作尝试进行多模态推理，让模型能够“边看边想”；但这些方法仍属于比较初步的探索。因此，从具身认知的角度看，MLLM 的思考能力与人类仍有显著差距。

LLM 既不是基于形式逻辑规则（如命题逻辑）进行推理，也不是按照计算规则进行算术运算。它可以通过其生成机制模拟，呈现出一定的启发式推理和计算能力，但在处理复杂问题时，由于缺乏严谨性，容易产生错误。因此，LLM 在这方面存在局限性。

LLM 是否有创造力，还是一个开放式的问题，这也依赖于对创造力的定义。创新分渐进式创新和颠覆性创新。通过观察可以发现，LLM 应该也具备渐进式创新能力。而颠覆式创新，如相对论理论的建立，LLM 是否能够做到，目前尚无定论。Ilya Sutskever 认为 LLM 可以做插值（interpolation），但外推（extrapolation）是开放问题，也是类似的想法。

LLM 并不存在对应人的意识机制，虽然我们会感到与 LLM 对话时有与真人交互的感觉。意识是指人的心智中感受到的对内部身体和外部环境的知觉。意识是清醒时人脑处于的一种状态，与其相对的其他状态是深度睡眠、昏迷、死亡。意识是主观的，是每个人以自我为中心的精神活动，对我们每个人来说自己的意识是持续的、一贯的、稳定的。同时，意识又是客观的，它对应着人脑神经系统的高层次处理，由人脑神经系统的低层次处理支撑。全局工作空间理论 (Global Workspace Theory) 认为意识是脑内信息的全局广播。

6 结语

本文从实现方法、工作机制角度讨论 LLM 的语言与思考能力。认为从某种意义上说，LLM 已经达到或超过人类的语言和思考水平。

大语言模型 (LLM) 本质上学习到了语言数据中的模式，也就是规律，并且能够运用这些模式，特别是高阶模式，展现出智能性的行为。

LLM 学习到的能力可以用 Next Token Prediction 来简单概括，但其实是非常有效的实现原理和方法的集大成之结果；数据规模和模型规模也起到了重要作用。预训练通过数据压缩，能使模型找到大量多样性的数据中的规律，后训练通过策略模型，对模型微调使其能更合理地完成任务和实施推理。梯度下降结合反向传播可以使模型的参数得以调整，更好地表示数据模式。Transformer 架构通过注意力、FFN、残差机制能很好地表示数据中的层次化的多样的以及灵活组合的范式。

LLM 内部存在着复杂的工作机制。SAE、CLT 等分析工具发现，模型中真的存在大量的不同层次的特征，而且这些特征形成了回路，能够在学习中被记忆，在预测中被检索。

大语言模型实际代表了在序列数据中学习模式的一种通用技术，一种范式，它不仅可以用于语言数据，也可以用于图像等其他类型的数据。

参考文献

- [1] Mikhail Belkin, Daniel Hsu, Siyuan Ma, and Soumik Mandal. Reconciling modern machine-learning practice and the classical bias-

- variance trade-off. *Proceedings of the National Academy of Sciences*, 116(32):15849–15854, 2019.
- [2] Nelson Elhage, Tristan Hume, Catherine Olsson, Nicholas Schiefer, Tom Henighan, Shauna Kravec, Zac Hatfield-Dodds, Robert Lasenby, Dawn Drain, Carol Chen, Roger Grosse, Sam McCandlish, Jared Kaplan, Dario Amodei, Martin Wattenberg, and Christopher Olah. Toy models of superposition, 2022.
- [3] Adam Tauman Kalai, Ofir Nachum, Santosh S. Vempala, and Edwin Zhang. Why language models hallucinate, 2025.
- [4] Jared Kaplan, Sam McCandlish, Tom Henighan, Tom B Brown, Benjamin Chess, Rewon Child, Scott Gray, Alec Radford, Jeffrey Wu, and Dario Amodei. Scaling laws for neural language models. *arXiv preprint arXiv:2001.08361*, 2020.
- [5] Nitish Shirish Keskar, Dheevatsa Mudigere, Jorge Nocedal, Mikhail Smelyanskiy, and Ping Tak Peter Tang. On large-batch training for deep learning: Generalization gap and sharp minima. *arXiv preprint arXiv:1609.04836*, 2016.
- [6] Trung Quoc Luong, Xinbo Zhang, Zhanming Jie, Peng Sun, Xiaoran Jin, and Hang Li. Reft: Reasoning with reinforced fine-tuning, 2024.
- [7] Chiyuan Zhang, Samy Bengio, Moritz Hardt, Benjamin Recht, and Oriol Vinyals. Understanding deep learning requires rethinking generalization, 2017.
- [8] Shaohua Zhang, Yuan Lin, and Hang Li. Memory retrieval and consolidation in large language models through function tokens, 2025.
- [9] Chujie Zheng, Kai Dang, Bowen Yu, Mingze Li, Huiqiang Jiang, Junrong Lin, Yuqiong Liu, Hao Lin, Chencan Wu, Feng Hu, An Yang, Jingren Zhou, and Junyang Lin. Stabilizing reinforcement learning with llms: Formulation and practices, 2025.